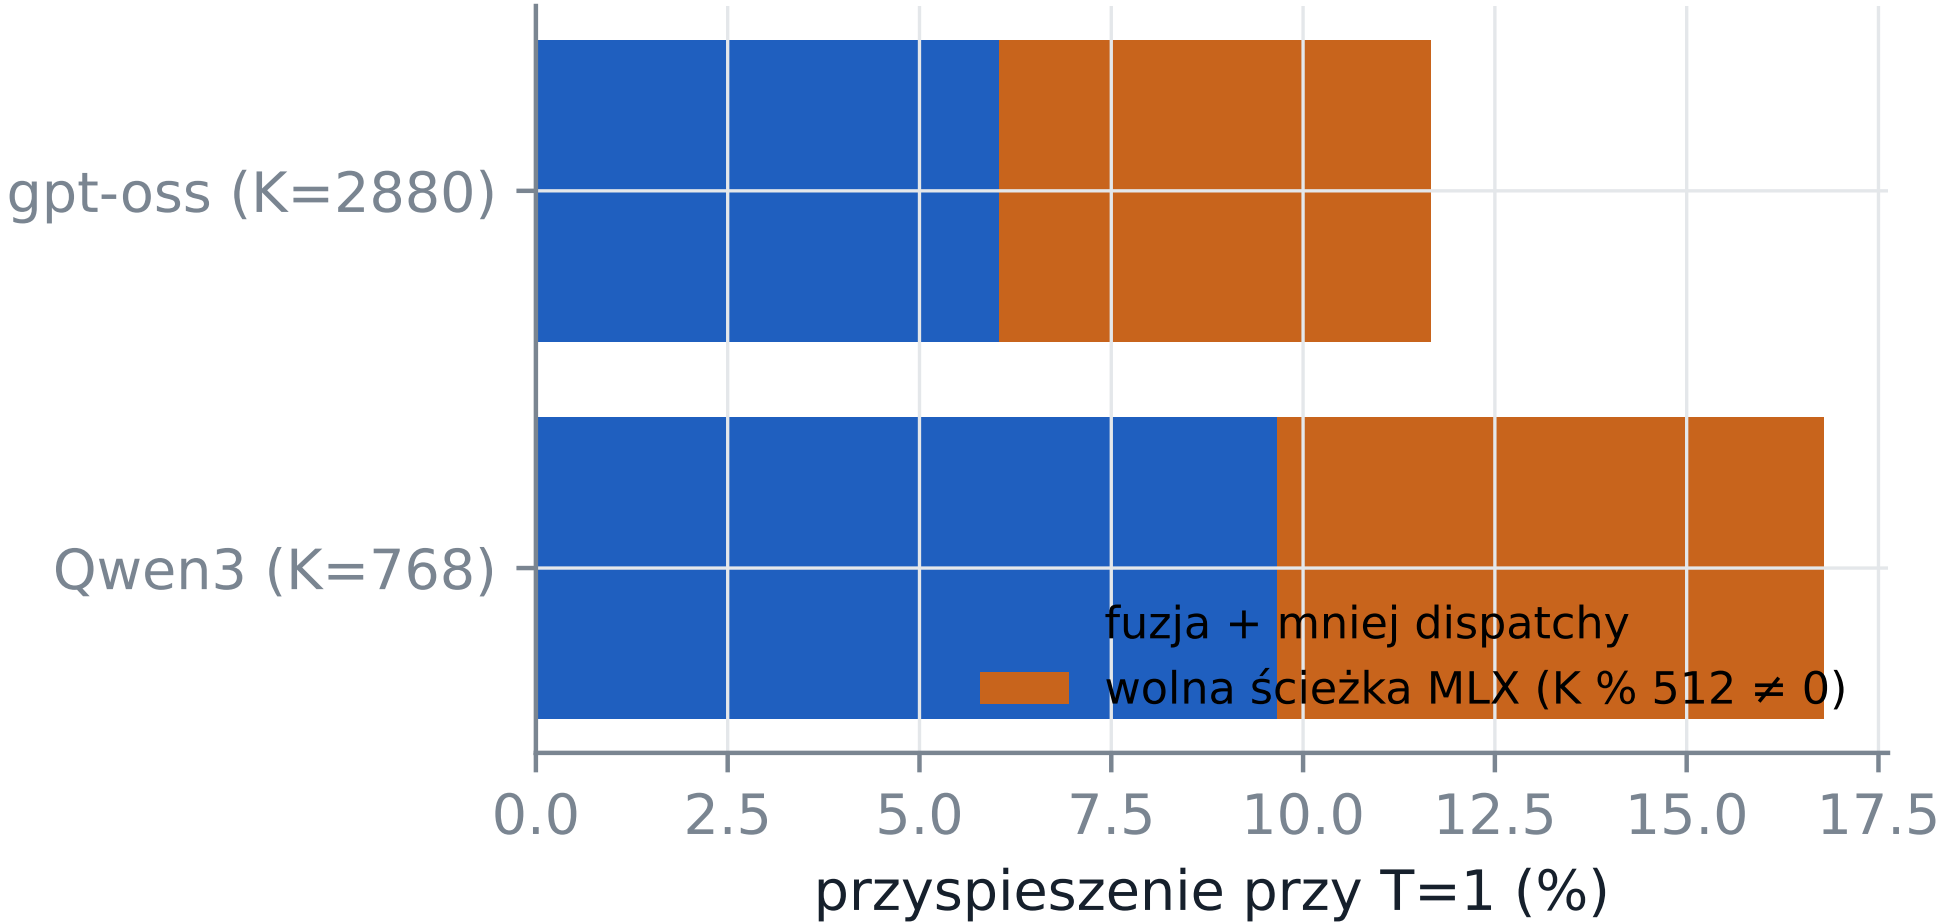
gpt-oss (K=2880)
Qwen3 (K=768)
fuzja + mniej dispatchy
wolna ścieżka MLX (K % 512 ≠ 0)
0.0
2.5
5.0
7.5
10.0
12.5
15.0
17.5
przyspieszenie przy T=1 (%)