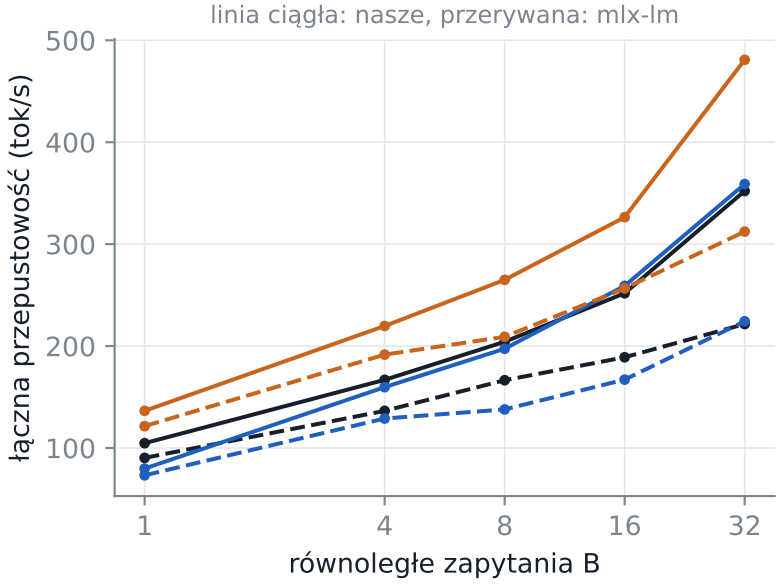
linia ciągła: nasze, przerywana: mlx-lm
łączna przepustowość (tok/s)
500
400
300
200
100
1
4
8
16
32
równoległe zapytania B

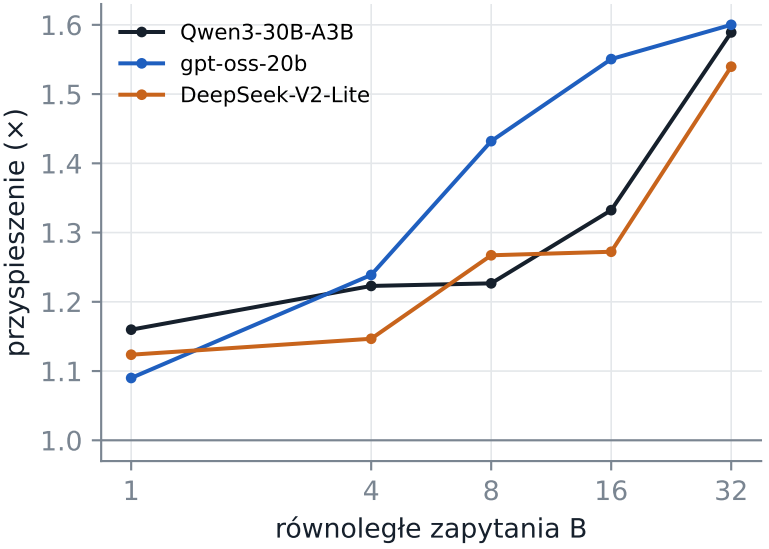
Qwen3-30B-A3B
gpt-oss-20b
DeepSeek-V2-Lite
przyspieszenie (×)
1.6
1.5
1.4
1.3
1.2
1.1
1.0
1
4
8
16
32
równoległe zapytania B