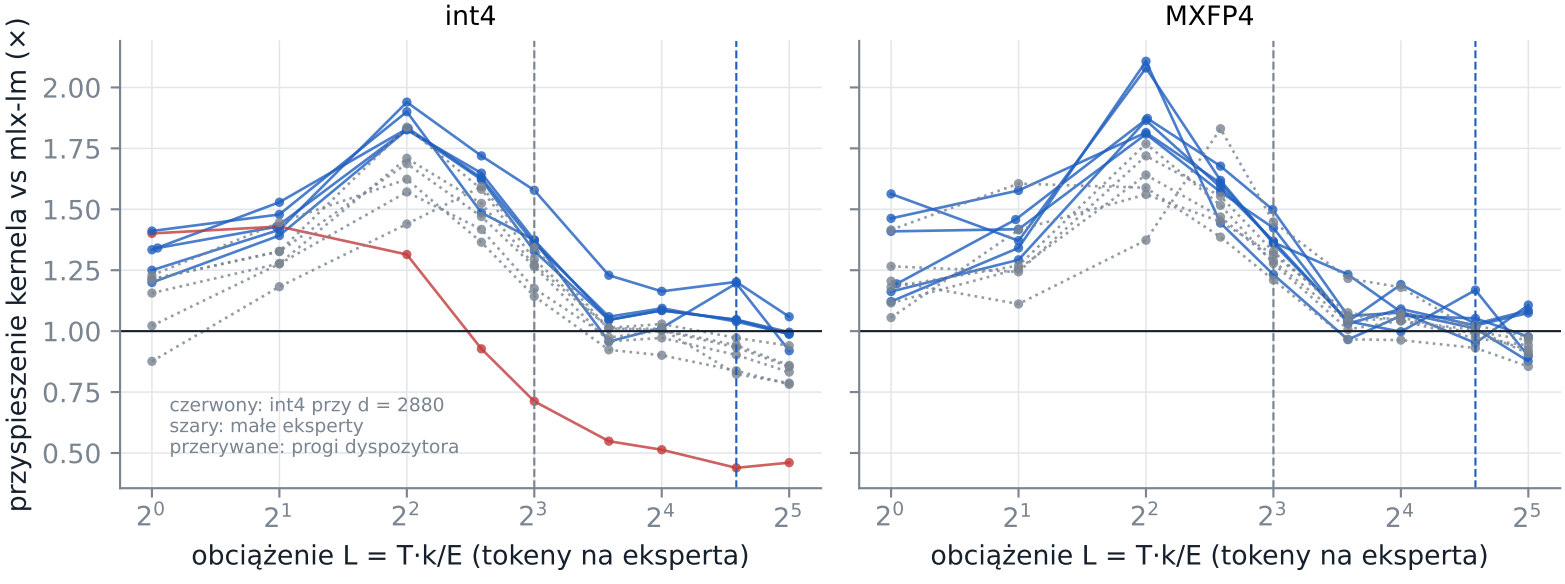
int4
MXFP4
przyspieszenie kernela vs mlx-lm (×)
2.00
1.75
1.50
1.25
1.00
0.75
0.50
czerwony: int4 przy d = 2880
szary: małe eksperty
przerywane: progi dyspozytora
2^0
2^1
2^2
2^3
2^4
2^5
obciążenie L = T·k/E (tokeny na eksperta)
obciążenie L = T·k/E (tokeny na eksperta)