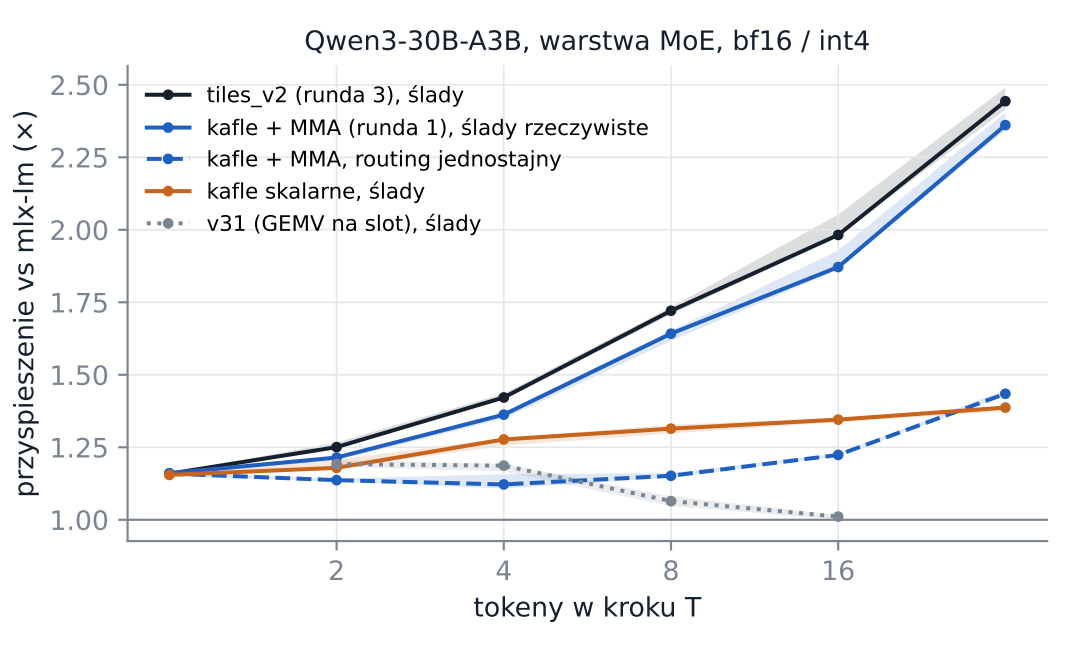
Qwen3-30B-A3B, warstwa MoE, bf16 / int4
tiles_v2 (runda 3), ślady
kafle + MMA (runda 1), ślady rzeczywiste
kafle + MMA, routing jednostajny
kafle skalarne, ślady
v31 (GEMV na slot), ślady
przyspieszenie vs mlx-lm (×)
2.50
2.25
2.00
1.75
1.50
1.25
1.00
2
4
8
16
tokeny w kroku T