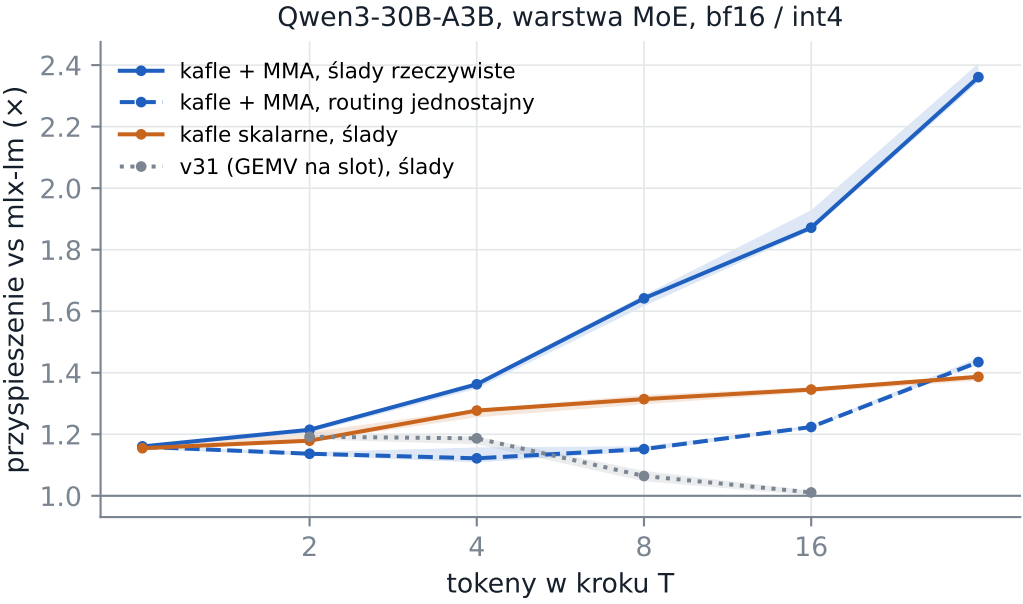
Qwen3-30B-A3B, warstwa MoE, bf16 / int4
kafle + MMA, ślady rzeczywiste
kafle + MMA, routing jednostajny
kafle skalarne, ślady
v31 (GEMV na slot), ślady
przyspieszenie vs mlx-lm (x)
2.4
2.2
2.0
1.8
1.6
1.4
1.2
1.0
2
4
8
16
tokeny w kroku T